

Sujet:

GLM : RÉGRESSION DE POISSON
APPLIQUÉE AU NOMBRE DE
RÉCOMPENSES ACADÉMIQUES

Réalisé par : SIDI Mohamed - ESBD
YAHYA Mohamed Yahya - ESBD
SIDI ABDOULLAH Lalla - ESBD
Encadré par : PhD. BADAQUI Fadoua

Table des matières

1	Introduction et problématique	1
1	Introduction	1
2	Contexte de l'étude	2
3	Problématique	2
4	Objectifs du travail	2
5	Démarche adoptée	3
6	Organisation du rapport	3
2	Cadre théorique de la régression de Poisson	5
1	Introduction aux modèles linéaires généralisés	5
2	Spécificité des variables de comptage	6
3	La loi de Poisson	6
4	Le modèle de régression de Poisson	7
5	Application au cas étudié	7
6	Estimation des paramètres par maximum de vraisemblance	8
7	Test de significativité individuelle des coefficients	9
8	Interprétation des coefficients	10
9	Test global du modèle	11
10	Déviance et adéquation du modèle	11
11	Statistique de Pearson et dispersion	12
12	Analyse des résidus	13
13	Critères de comparaison des modèles	13
13.1	Critère AIC	13
13.2	Test du rapport de vraisemblance entre modèles emboîtés	14
14	Validation prédictive	14

15	Courbe ROC dans le cadre d'une variable de comptage	15
16	Synthèse du cadre théorique	16
3	Description des données et analyse exploratoire	17
1	Présentation générale de la base	17
2	Description des variables	17
3	Vérification de la nature de la variable réponse	18
4	Statistiques descriptives de la variable Awards	18
5	Distribution empirique de Awards	19
6	Statistiques descriptives de Math_Score	20
7	Relation entre Math_Score et Awards	22
8	Découpage apprentissage-validation	23
9	Conclusion de l'analyse exploratoire	24
4	Méthodologie de modélisation	25
1	Introduction	25
2	Préparation des données	25
3	Découpage apprentissage-validation	26
4	Modèle de Poisson simple	26
5	Modèle de Poisson quadratique	27
6	Estimation par maximum de vraisemblance	28
7	Tests de significativité	28
7.1	Test individuel de Wald	28
7.2	Test global par rapport de vraisemblance	29
8	Adéquation des modèles	29
8.1	Déviance résiduelle	30
8.2	Statistique de Pearson	30
9	Analyse des résidus	30
9.1	Résidus de Pearson	30
9.2	Résidus de déviance	30
10	Comparaison des modèles	31
10.1	Critère AIC	31
10.2	Test entre modèles emboîtés	31

11	Validation prédictive sur l'échantillon test	32
11.1	Erreur absolue moyenne	32
11.2	Racine de l'erreur quadratique moyenne	32
11.3	Déviance de Poisson sur l'échantillon test	32
12	Courbe ROC et classification	32
13	Diagnostic des observations influentes	33
14	Synthèse de la méthodologie	34
5	Résultats empiriques des modèles de Poisson	35
1	Introduction	35
2	Estimation du modèle de Poisson simple	35
3	Interprétation des coefficients du modèle simple	36
4	Significativité globale du modèle simple	37
5	Adéquation du modèle simple	38
6	Analyse des résidus du modèle simple	39
7	Estimation du modèle de Poisson quadratique	40
8	Interprétation du terme quadratique	41
9	Significativité du terme quadratique	41
10	Adéquation du modèle quadratique	42
11	Analyse des résidus du modèle quadratique	43
12	Diagnostic d'influence du modèle quadratique	43
13	Synthèse des résultats empiriques	45
6	Validation, comparaison des modèles et choix final	47
1	Introduction	47
2	Validation prédictive du modèle simple M_1	47
3	Validation prédictive du modèle quadratique M_2	49
4	Comparaison prédictive des deux modèles	50
5	Comparaison par test du rapport de vraisemblance	51
6	Construction de la courbe ROC	51
7	Résultats de la courbe ROC	52
8	Seuil optimal et matrice de confusion	53
9	Indicateurs de classification	54

10	Choix du modèle final	55
11	Interprétation du modèle final	56
12	Synthèse	57
7	Discussion, limites et conclusion générale	59
1	Introduction	59
2	Discussion du choix du modèle final	59
3	Interprétation statistique du modèle final	60
4	Interprétation pratique	62
5	Qualité d'ajustement du modèle final	62
6	Performance prédictive	63
7	Performance de classification	64
8	Discussion des observations influentes	65
9	Limites de l'étude	66
9.1	Nombre limité de variables explicatives	66
9.2	Forte proportion de zéros	66
9.3	Sous-dispersion	67
9.4	Taille de l'échantillon de validation	67
10	Prolongements possibles	67
10.1	Ajouter d'autres variables explicatives	67
10.2	Tester d'autres modèles de comptage	67
10.3	Utiliser une validation croisée	68
11	Conclusion générale	68
8	Annexe : Code R et ressources numériques	70
1	Disponibilité du code	70
2	Lien vers le dépôt GitHub	70
3	Packages utilisés	70
4	Conclusion	70

Table des figures

5.1	Distribution de la variable Awards	20
6.1	Distribution de la variable Math_Score	21
7.1	Relation entre Math_Score et Awards	22
6.1	Résidus de Pearson du modèle M_1	39
6.2	Valeurs observées et ajustées du modèle M_1	40
12.1	Distance de Cook du modèle M_2	45
12.2	Leverage du modèle M_2	45
2.1	Validation du modèle simple M_1 sur l'échantillon test	49
7.1	Courbe ROC du modèle de Poisson sur l'échantillon test	53
7.2	Comparaison des courbes ROC des modèles M_1 et M_2	53

Chapitre 1

Introduction et problématique

1 Introduction

L'étude statistique d'une variable de comptage nécessite un modèle adapté à la nature discrète et positive de la variable étudiée. Dans le cadre de ce travail, on s'intéresse au nombre de récompenses obtenues par des individus dans une compétition académique. La variable d'intérêt, notée **Awards**, représente un nombre d'événements observés. Elle prend donc des valeurs entières positives ou nulles.

Dans un premier réflexe, on pourrait penser à utiliser un modèle de régression linéaire classique afin d'expliquer le nombre de récompenses à partir du score en mathématiques. Cependant, cette approche n'est pas adaptée à ce type de variable réponse. En effet, le modèle linéaire classique repose sur plusieurs hypothèses fortes, notamment la normalité des erreurs, la variance constante et la possibilité de prédire des valeurs réelles quelconques. Or, dans le cas d'une variable de comptage, les valeurs prédites doivent rester positives ou nulles, et la variance dépend généralement de la moyenne.

Pour cette raison, le recours aux modèles linéaires généralisés est plus approprié. Ces modèles permettent de conserver une structure linéaire au niveau d'un prédicteur, tout en utilisant une loi de probabilité adaptée à la variable réponse. Dans le cas d'une variable de comptage, la loi de Poisson constitue le choix naturel lorsque l'on cherche à modéliser le nombre d'apparitions d'un événement.

La régression de Poisson permet ainsi de modéliser l'espérance conditionnelle de la variable réponse en fonction d'une ou plusieurs variables explicatives. Dans ce travail, on cherche plus précisément à expliquer le nombre de récompenses obtenues à partir du score en mathématiques, noté **Math_Score**.

2 Contexte de l'étude

La base de données utilisée dans ce projet contient deux variables principales :

- **Awards** : nombre de récompenses obtenues par un individu ;
- **Math_Score** : score obtenu en mathématiques.

La variable **Awards** est la variable réponse du modèle. Elle correspond à une variable quantitative discrète de comptage. La variable **Math_Score** est utilisée comme variable explicative afin d'étudier son effet sur le nombre moyen de récompenses.

L'objectif n'est donc pas seulement de constater une liaison entre les deux variables, mais de construire un modèle statistique permettant d'estimer et d'interpréter l'effet du score en mathématiques sur le nombre attendu de récompenses.

3 Problématique

La problématique centrale de ce travail peut être formulée de la manière suivante :
Comment le score en mathématiques permet-il d'expliquer le nombre de récompenses obtenues par un individu dans une compétition académique, à l'aide d'un modèle de régression de Poisson ?

Cette question conduit à plusieurs sous-questions statistiques :

- La variable **Awards** possède-t-elle bien les caractéristiques d'une variable de comptage ?
- Le score en mathématiques a-t-il un effet significatif sur le nombre moyen de récompenses ?
- Le modèle de Poisson simple est-il suffisant pour décrire la relation observée ?
- Un modèle plus flexible, intégrant un terme quadratique, améliore-t-il l'ajustement ?
- Le modèle retenu est-il adéquat au sens de la déviance et de la statistique de Pearson ?
- Quelle est la qualité prédictive du modèle sur un échantillon de validation ?

4 Objectifs du travail

L'objectif général de ce travail est d'appliquer la méthodologie des modèles linéaires généralisés au cas d'une variable de comptage. Plus précisément, il s'agit de :

1. décrire les données et vérifier la nature statistique de la variable réponse ;
2. justifier le choix de la régression de Poisson ;

3. ajuster un premier modèle de Poisson simple ;
4. tester la significativité des coefficients et du modèle global ;
5. vérifier l'adéquation du modèle à l'aide de la déviance et de la statistique de Pearson ;
6. comparer le modèle simple à un modèle de Poisson quadratique ;
7. valider les performances prédictives sur un échantillon test ;
8. interpréter les résultats obtenus de manière statistique et pratique.

5 Démarche adoptée

La démarche suivie dans ce rapport respecte les étapes usuelles de modélisation vues dans le cadre du cours sur les modèles linéaires généralisés. Elle peut être résumée comme suit :

Description des données $\longrightarrow$ Choix du modèle $\longrightarrow$ Estimation $\longrightarrow$ Tests statistiques $\longrightarrow$ Adéquation

Dans un premier temps, une analyse descriptive est réalisée afin d'étudier la distribution de la variable **Awards** et sa relation avec **Math_Score**. Ensuite, les données sont divisées en deux parties : un échantillon d'apprentissage représentant 80% des observations et un échantillon de validation représentant 20% des observations.

Le modèle est estimé sur l'échantillon d'apprentissage. Sa performance est ensuite évaluée sur l'échantillon de validation. Deux modèles sont considérés :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i$$

et

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

Le modèle final est choisi en comparant les modèles selon plusieurs critères : le critère AIC, le test du rapport de vraisemblance, les erreurs de prédiction sur l'échantillon test, ainsi que la courbe ROC après transformation de la variable réponse en variable binaire.

6 Organisation du rapport

Le rapport est organisé de la manière suivante. Le deuxième chapitre présente le

cadre théorique de la régression de Poisson et rappelle les éléments essentiels des modèles linéaires généralisés. Le troisième chapitre décrit les données utilisées et présente les premières analyses descriptives. Le quatrième chapitre expose la méthodologie d'estimation et de validation. Le cinquième chapitre présente les résultats empiriques des modèles ajustés. Le sixième chapitre est consacré à la validation, à la comparaison des modèles et à la courbe ROC. Enfin, le dernier chapitre propose une discussion des résultats, les limites de l'étude et la conclusion générale.

Chapitre 2

Cadre théorique de la régression de Poisson

1 Introduction aux modèles linéaires généralisés

Les modèles linéaires généralisés, ou GLM, constituent une extension du modèle linéaire classique. Dans un modèle linéaire usuel, on suppose généralement que la variable réponse est continue, que les erreurs sont normalement distribuées et que la variance est constante. Ces hypothèses ne sont pas toujours adaptées, notamment lorsque la variable réponse est discrète, binaire, positive ou issue d'un phénomène de comptage.

Dans le cas étudié, la variable réponse **Awards** représente un nombre de récompenses. Il s'agit donc d'une variable quantitative discrète de comptage. Une telle variable ne peut pas être correctement modélisée par une régression linéaire classique, car cette dernière peut produire des prédictions négatives et repose sur une hypothèse de normalité peu compatible avec des données de comptage.

Les modèles linéaires généralisés permettent de dépasser cette limite en combinant trois éléments fondamentaux :

1. une composante aléatoire, qui précise la loi suivie par la variable réponse ;
2. une composante systématique, appelée prédicteur linéaire ;
3. une fonction de lien, qui relie l'espérance de la variable réponse au prédicteur linéaire.

Dans le cadre général, si Y_i désigne la variable réponse de l'individu i , on note :

$$\mu_i = \mathbb{E}(Y_i \mid X_i).$$

Le prédicteur linéaire est donné par :

$$\eta_i = X_i' \beta = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

La fonction de lien g permet de relier μ_i au prédicteur linéaire :

$$g(\mu_i) = \eta_i = X_i' \beta.$$

Ainsi, le modèle reste linéaire au niveau du prédicteur η_i , mais pas nécessairement au niveau de l'espérance μ_i .

2 Spécificité des variables de comptage

Une variable de comptage prend des valeurs entières positives ou nulles :

$$Y_i \in \{0, 1, 2, \dots\}.$$

Elle représente généralement le nombre d'apparitions d'un événement pendant une période donnée ou dans une situation donnée. Dans notre application, **Awards** représente le nombre de récompenses obtenues par un individu.

Pour ce type de variable, la loi de Poisson constitue un modèle naturel. Elle est adaptée lorsque l'on cherche à modéliser le nombre d'occurrences d'un événement, surtout lorsque les grandes valeurs sont relativement rares.

3 La loi de Poisson

On dit qu'une variable aléatoire Y suit une loi de Poisson de paramètre $\lambda > 0$, et on note :

$$Y \sim \mathcal{P}(\lambda),$$

si sa fonction de probabilité est donnée par :

$$\mathbb{P}(Y = y) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 0, 1, 2, \dots$$

Le paramètre λ représente à la fois l'espérance et la variance de la loi :

$$\mathbb{E}(Y) = \lambda,$$

$$\text{Var}(Y) = \lambda.$$

Cette propriété est appelée équidispersion. Elle signifie que, dans un modèle de Poisson standard, la moyenne conditionnelle et la variance conditionnelle sont égales :

$$\mathbb{E}(Y_i | X_i) = \text{Var}(Y_i | X_i) = \lambda_i.$$

Cette hypothèse devra être vérifiée empiriquement à travers les statistiques d'adéquation du modèle, notamment la déviance résiduelle et la statistique de Pearson.

4 Le modèle de régression de Poisson

Dans la régression de Poisson, on suppose que la variable réponse conditionnellement aux variables explicatives suit une loi de Poisson :

$$Y_i | X_i \sim \mathcal{P}(\lambda_i).$$

L'espérance conditionnelle est donc :

$$\mathbb{E}(Y_i | X_i) = \lambda_i.$$

Comme λ_i doit être strictement positif, on utilise généralement la fonction de lien logarithmique. Le modèle s'écrit alors :

$$\ln(\lambda_i) = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

Ce qui revient à écrire :

$$\lambda_i = \exp(\beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}).$$

La fonction exponentielle garantit que :

$$\lambda_i > 0.$$

Ainsi, le modèle de Poisson évite le problème des prédictions négatives que l'on pourrait obtenir avec une régression linéaire classique.

5 Application au cas étudié

Dans notre étude, la variable réponse est :

$$Y_i = Awards_i.$$

La variable explicative principale est :

$$X_i = Math_Score_i.$$

Un premier modèle de Poisson simple peut donc être formulé comme suit :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 Math_Score_i.$$

Dans ce modèle, λ_i représente le nombre moyen attendu de récompenses pour un individu ayant un score en mathématiques donné.

Cependant, la relation entre le score en mathématiques et le nombre de récompenses peut ne pas être strictement log-linéaire. Pour prendre en compte une éventuelle courbure, on considère aussi un modèle quadratique :

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 Math_Score_i + \beta_2 Math_Score_i^2.$$

Ce deuxième modèle permet de tester si l'effet du score en mathématiques varie selon le niveau du score.

6 Estimation des paramètres par maximum de vraisemblance

Les paramètres du modèle de Poisson sont estimés par la méthode du maximum de vraisemblance.

Pour une observation i , la probabilité d'observer $Y_i = y_i$ est :

$$\mathbb{P}(Y_i = y_i \mid X_i) = \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

Pour un échantillon de n observations indépendantes, la vraisemblance est :

$$L(\beta) = \prod_{i=1}^n \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

Comme :

$$\lambda_i = \exp(X_i' \beta),$$

on peut écrire :

$$L(\beta) = \prod_{i=1}^n \frac{[\exp(X_i' \beta)]^{y_i} e^{-\exp(X_i' \beta)}}{y_i!}.$$

La log-vraisemblance est alors :

$$\ell(\beta) = \sum_{i=1}^n [y_i X_i' \beta - \exp(X_i' \beta) - \ln(y_i!)] .$$

L'estimateur du maximum de vraisemblance est défini par :

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta).$$

Contrairement au modèle linéaire classique, les estimateurs ne possèdent pas de forme explicite simple. Ils sont obtenus par des méthodes numériques itératives, telles que l'algorithme de Newton-Raphson ou l'algorithme de Fisher scoring, utilisé dans la fonction `glm()` de R.

7 Test de significativité individuelle des coefficients

Après estimation du modèle, il est nécessaire de tester si chaque variable explicative a un effet significatif sur la variable réponse.

Pour un coefficient β_j , on teste :

$$H_0 : \beta_j = 0$$

contre :

$$H_1 : \beta_j \neq 0.$$

Le test utilisé est le test de Wald. La statistique associée est :

$$W_j = \left(\frac{\hat{\beta}_j}{\hat{\sigma}(\hat{\beta}_j)} \right)^2 .$$

Sous l'hypothèse nulle H_0 , cette statistique suit asymptotiquement une loi du khi-deux à un degré de liberté :

$$W_j \sim \chi^2(1).$$

De manière équivalente, R fournit la statistique :

$$z_j = \frac{\widehat{\beta}_j}{\widehat{\sigma}(\widehat{\beta}_j)}.$$

Si la p-value associée est inférieure au seuil de 5%, on rejette H_0 , ce qui signifie que la variable explicative a un effet significatif sur le nombre moyen attendu de récompenses.

8 Interprétation des coefficients

Dans un modèle de Poisson avec lien logarithmique, les coefficients ne s'interprètent pas directement comme dans une régression linéaire classique.

Le modèle s'écrit :

$$\ln(\lambda_i) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}.$$

Si la variable X_j augmente d'une unité, toutes choses égales par ailleurs, alors le nombre moyen attendu λ_i est multiplié par :

$$\exp(\beta_j).$$

Ainsi :

- si $\beta_j > 0$, alors $\exp(\beta_j) > 1$, et la variable augmente le nombre moyen attendu ;
- si $\beta_j < 0$, alors $\exp(\beta_j) < 1$, et la variable diminue le nombre moyen attendu ;
- si $\beta_j = 0$, alors $\exp(\beta_j) = 1$, et la variable n'a pas d'effet multiplicatif.

L'effet peut aussi être exprimé en pourcentage :

$$(\exp(\beta_j) - 1) \times 100.$$

Dans le modèle simple M_1 , cette interprétation est directe pour β_1 . Dans le modèle quadratique M_2 , l'effet marginal du score en mathématiques dépend du niveau de `Math_Score`. En effet :

$$\ln(\lambda_i) = \beta_0 + \beta_1 x_i + \beta_2 x_i^2.$$

La variation locale du logarithme de l'espérance par rapport à x_i est alors :

$$\frac{\partial \ln(\lambda_i)}{\partial x_i} = \beta_1 + 2\beta_2 x_i.$$

Donc l'effet multiplicatif local d'un point supplémentaire de score dépend du niveau initial du score.

9 Test global du modèle

Le test global permet d'évaluer si le modèle avec variables explicatives améliore significativement l'ajustement par rapport au modèle réduit à la constante.

Le modèle réduit s'écrit :

$$M_0 : \ln(\lambda_i) = \beta_0.$$

Le modèle complet s'écrit :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}.$$

On teste :

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

contre :

$$H_1 : \exists j, \beta_j \neq 0.$$

La statistique du rapport de vraisemblance peut s'exprimer à partir des déviations :

$$LR = D_{\text{réduit}} - D_{\text{complet}}.$$

Sous l'hypothèse nulle, cette statistique suit approximativement une loi du khi-deux dont le nombre de degrés de liberté correspond à la différence du nombre de paramètres entre les deux modèles :

$$LR \sim \chi^2(q).$$

Si la p-value est inférieure à 5%, le modèle complet est considéré comme globalement significatif.

10 Déviance et adéquation du modèle

L'adéquation du modèle consiste à vérifier si le modèle ajusté représente correctement les données observées. Pour cela, on compare le modèle ajusté au modèle saturé. Le modèle saturé est un modèle théorique qui ajuste parfaitement les données, c'est-à-dire pour lequel :

$$\hat{\mu}_i = y_i.$$

La déviance résiduelle du modèle de Poisson est donnée par :

$$D = 2 \sum_{i=1}^n \left[y_i \ln \left(\frac{y_i}{\hat{\lambda}_i} \right) - (y_i - \hat{\lambda}_i) \right].$$

Lorsque $y_i = 0$, le terme $y_i \ln(y_i/\hat{\lambda}_i)$ est pris égal à zéro par convention.

Sous l'hypothèse que le modèle est adéquat, la déviance résiduelle suit approximativement une loi du khi-deux :

$$D \sim \chi^2(n - k),$$

où k est le nombre de paramètres estimés.

On compare donc la déviance résiduelle aux degrés de liberté :

$$ddl = n - k.$$

Un indicateur pratique est le rapport :

$$\frac{D}{ddl}.$$

Si ce rapport est proche de 1, l'ajustement est généralement considéré comme satisfaisant. Une valeur très supérieure à 1 peut indiquer une surdispersion. Une valeur très inférieure à 1 peut signaler une sous-dispersion ou un ajustement très serré.

11 Statistique de Pearson et dispersion

Une autre mesure d'adéquation est la statistique de Pearson :

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\lambda}_i)^2}{\hat{\lambda}_i}.$$

Dans le modèle de Poisson, on utilise $\hat{\lambda}_i$ au dénominateur car :

$$\text{Var}(Y_i | X_i) = \lambda_i.$$

Comme pour la déviance, on examine le rapport :

$$\frac{X^2}{ddl}.$$

Lorsque ce rapport est proche de 1, cela indique que la variabilité observée est

compatible avec l'hypothèse de Poisson. Si le rapport est nettement supérieur à 1, il peut y avoir surdispersion :

$$\text{Var}(Y_i | X_i) > \mathbb{E}(Y_i | X_i).$$

Dans ce cas, le modèle de Poisson standard peut sous-estimer les erreurs standards des coefficients. Des modèles alternatifs comme le quasi-Poisson ou la régression binomiale négative peuvent alors être envisagés.

12 Analyse des résidus

L'analyse des résidus complète l'étude de l'adéquation du modèle. Dans un GLM de Poisson, les résidus bruts sont définis par :

$$e_i = y_i - \hat{\lambda}_i.$$

Cependant, on utilise plus souvent les résidus de Pearson et les résidus de déviance. Le résidu de Pearson est :

$$r_{P,i} = \frac{y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}.$$

Le résidu de déviance est :

$$r_{D,i} = \text{signe}(y_i - \hat{\lambda}_i) \sqrt{2 \left[y_i \ln \left(\frac{y_i}{\hat{\lambda}_i} \right) - (y_i - \hat{\lambda}_i) \right]}.$$

Les résidus permettent d'identifier des observations mal ajustées, des valeurs atypiques ou des structures non prises en compte par le modèle.

13 Critères de comparaison des modèles

Lorsque plusieurs modèles sont possibles, il est nécessaire de les comparer à l'aide de critères objectifs.

13.1 Critère AIC

Le critère d'information d'Akaike est défini par :

$$AIC = -2\ell(\hat{\beta}) + 2k,$$

où k est le nombre de paramètres estimés. Le modèle préféré est celui qui possède l'AIC le plus faible.

L'AIC cherche un compromis entre qualité d'ajustement et complexité du modèle.

Un modèle plus complexe peut mieux s'ajuster aux données, mais il est pénalisé par le terme $2k$.

13.2 Test du rapport de vraisemblance entre modèles emboîtés

Lorsque deux modèles sont emboîtés, on peut les comparer à l'aide du test du rapport de vraisemblance. Si M_1 est un modèle simple et M_2 un modèle plus général, la statistique est :

$$LR = D_{M_1} - D_{M_2}.$$

Sous l'hypothèse nulle selon laquelle le modèle simple est suffisant, cette statistique suit approximativement une loi du khi-deux avec un nombre de degrés de liberté égal à la différence du nombre de paramètres entre les deux modèles.

14 Validation prédictive

La validation prédictive consiste à évaluer le modèle sur des données qui n'ont pas été utilisées pour son estimation. Dans ce travail, les données sont divisées en deux parties :

80% pour l'apprentissage,

20% pour la validation.

Le modèle est estimé sur l'échantillon d'apprentissage, puis utilisé pour prédire les valeurs de l'échantillon test.

Pour une observation i de l'échantillon test, la prédiction du nombre moyen d'awards est :

$$\hat{\lambda}_i = \exp(X_i' \hat{\beta}).$$

Les performances prédictives peuvent être évaluées par plusieurs indicateurs. L'erreur absolue moyenne est :

$$MAE = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} |y_i - \hat{\lambda}_i|.$$

La racine de l'erreur quadratique moyenne est :

$$RMSE = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (y_i - \hat{\lambda}_i)^2}.$$

Plus ces indicateurs sont faibles, meilleure est la qualité prédictive du modèle.

15 Courbe ROC dans le cadre d'une variable de comptage

La courbe ROC est naturellement utilisée pour évaluer un modèle de classification binaire. Or, dans notre cas, la variable **Awards** est une variable de comptage. Pour respecter cette logique, on définit une variable binaire :

$$Awards_i^* = \begin{cases} 1 & \text{si } Awards_i > 0, \\ 0 & \text{si } Awards_i = 0. \end{cases}$$

L'objectif devient alors d'évaluer la capacité du modèle à distinguer les individus ayant obtenu au moins une récompense de ceux n'en ayant obtenu aucune.

Dans un modèle de Poisson, on a :

$$\mathbb{P}(Y_i = 0) = e^{-\lambda_i}.$$

Par conséquent :

$$\mathbb{P}(Y_i > 0) = 1 - e^{-\lambda_i}.$$

Après estimation du modèle, on utilise donc le score prédictif :

$$\hat{p}_i = 1 - e^{-\hat{\lambda}_i}.$$

La courbe ROC est construite en faisant varier le seuil de classification appliqué à $\hat{p}_i$. Elle met en relation :

$$\text{Sensibilité} = \frac{TP}{TP + FN}$$

et

$$1 - \text{Spécificité} = 1 - \frac{TN}{TN + FP}.$$

L'aire sous la courbe ROC, appelée AUC, mesure la capacité globale de

discrimination du modèle. Une valeur proche de 1 indique une très bonne discrimination, tandis qu'une valeur proche de 0.5 indique une performance proche du hasard.

16 Synthèse du cadre théorique

Le cadre théorique retenu dans ce travail repose donc sur la régression de Poisson, adaptée aux variables de comptage. Le modèle utilise une fonction de lien logarithmique afin de garantir des prédictions strictement positives. Les paramètres sont estimés par maximum de vraisemblance, puis évalués à l'aide de tests de Wald, du test global par rapport de vraisemblance, de la déviance résiduelle, de la statistique de Pearson et de l'analyse des résidus.

Deux modèles seront comparés empiriquement : un modèle simple intégrant uniquement le score en mathématiques, et un modèle quadratique permettant de prendre en compte une éventuelle non-linéarité. Le choix final du modèle reposera sur les critères d'ajustement, la validation prédictive et la performance ROC.

Chapitre 3

Description des données et analyse exploratoire

1 Présentation générale de la base

La base de données utilisée dans ce travail est intitulée `competition_awards_data`. Elle contient des observations relatives à des individus participant à une compétition académique. L'objectif est d'étudier le lien entre le score obtenu en mathématiques et le nombre de récompenses reçues.

Après importation sous R, la base contient :

$$n = 200$$

observations et deux variables principales :

- `Awards` : nombre de récompenses obtenues ;
- `Math_Score` : score obtenu en mathématiques.

La variable `Awards` constitue la variable réponse du modèle. Elle représente un nombre d'événements observés. La variable `Math_Score` est utilisée comme variable explicative principale.

2 Description des variables

Le tableau suivant présente les deux variables retenues dans l'étude.

TABLE 2.1 – Description des variables utilisées

Variable	Type statistique	Rôle	Interprétation
Awards	Quantitative discrète	Variable réponse	Nombre de récompenses obtenues par un individu.
Math_Score	Quantitative continue	Variable explicative	Score obtenu par l'individu en mathématiques.

La variable **Awards** est donc adaptée à une modélisation par régression de Poisson, car elle prend des valeurs entières positives ou nulles. Cette propriété est essentielle : dans le cadre du cours, la régression de Poisson est utilisée lorsque la variable dépendante est une variable de comptage.

3 Vérification de la nature de la variable réponse

Avant d'ajuster un modèle de Poisson, il est nécessaire de vérifier que la variable réponse vérifie bien les conditions suivantes :

$$Y_i \geq 0$$

et

$$Y_i \in \mathbb{N}.$$

Sous R, la vérification a confirmé que la variable **Awards** est bien une variable de comptage. Elle prend uniquement des valeurs entières positives ou nulles. Le résultat obtenu est :

```
Awards est-elle une variable de comptage ? : TRUE
```

Cette vérification justifie le choix initial d'un modèle de régression de Poisson.

4 Statistiques descriptives de la variable Awards

Les statistiques descriptives obtenues pour la variable **Awards** sont présentées dans le tableau suivant.

TABLE 4.1 – Statistiques descriptives de la variable **Awards**

Indicateur	Valeur
Nombre d'observations	200
Minimum	0
Maximum	6
Moyenne	0.63
Variance	1.108643
Écart-type	1.052921
Nombre de zéros	124
Proportion de zéros	0.62

La variable **Awards** varie entre 0 et 6. La moyenne est égale à :

$$\bar{Y} = 0.63.$$

La variance empirique est égale à :

$$S_Y^2 = 1.108643.$$

On remarque donc que :

$$S_Y^2 > \bar{Y}.$$

Cette première comparaison suggère une possible surdispersion dans les données brutes. Cependant, cette conclusion ne peut pas être retenue définitivement à ce stade. En effet, la surdispersion doit être évaluée après ajustement du modèle, à l'aide de la déviance résiduelle et de la statistique de Pearson.

La base contient également une proportion importante de zéros :

$$\frac{124}{200} = 0.62.$$

Ainsi, 62% des individus n'ont obtenu aucune récompense. Cette forte concentration en zéro est une caractéristique importante de la variable réponse et devra être prise en compte lors de l'interprétation des résultats.


5 Distribution empirique de Awards

La distribution empirique de la variable **Awards** est donnée par le tableau suivant.

TABLE 5.1 – Distribution empirique de la variable **Awards**

Nombre de récompenses	Effectif
0	124
1	49
2	13
3	9
4	2
5	2
6	1

Cette distribution confirme que les grandes valeurs de **Awards** sont rares. La majorité des individus se situe entre 0 et 1 récompense, tandis que très peu d'individus obtiennent 4 récompenses ou plus. Ce comportement est typique d'une variable de comptage.

**FIGURE 5.1** – Distribution de la variable **Awards**

Le graphique de distribution met en évidence une forte concentration des observations en zéro. Il montre également une décroissance rapide des effectifs lorsque le nombre de récompenses augmente. Ce résultat renforce l'idée que la variable étudiée correspond bien à un phénomène de comptage.

6 Statistiques descriptives de Math_Score

Les statistiques descriptives de la variable explicative **Math_Score** sont présentées ci-dessous.

TABLE 6.1 – Statistiques descriptives de la variable `Math_Score`

Indicateur	Valeur
Minimum	30
Maximum	91
Moyenne	50.715
Écart-type	19.14803

Le score en mathématiques varie entre 30 et 91. La moyenne observée est :

$$\bar{X} = 50.715.$$

L'écart-type est relativement élevé :

$$S_X = 19.14803.$$

Cela indique une dispersion importante des scores en mathématiques dans l'échantillon. Cette variabilité est utile pour la modélisation, car elle permet d'étudier comment le nombre moyen de récompenses évolue selon le niveau du score.




FIGURE 6.1 – Distribution de la variable `Math_Score`

Le graphique de distribution de `Math_Score` montre que les scores sont répartis sur plusieurs niveaux, avec une concentration visible dans les scores faibles et intermédiaires. Cette distribution permettra d'expliquer les différences observées dans le nombre de récompenses.

7 Relation entre Math_Score et Awards

L'étape suivante consiste à examiner la relation entre la variable explicative et la variable réponse. L'analyse graphique montre une relation croissante entre **Math_Score** et **Awards**. Les individus ayant des scores plus élevés en mathématiques tendent à obtenir davantage de récompenses.

Les corrélations obtenues sont les suivantes :

$$r_{\text{Pearson}} = 0.883521.$$

$$r_{\text{Spearman}} = 0.8638038.$$

Ces deux valeurs indiquent une association positive forte entre le score en mathématiques et le nombre de récompenses. La corrélation de Pearson mesure une liaison linéaire globale, tandis que la corrélation de Spearman mesure une relation monotone. Les deux coefficients étant élevés, ils suggèrent une relation positive nette entre les deux variables.




FIGURE 7.1 – Relation entre Math_Score et Awards

Le graphique confirme que le nombre de récompenses augmente avec le score en mathématiques. La tendance observée n'est toutefois pas nécessairement strictement linéaire sur l'échelle logarithmique. Cette remarque justifie l'estimation de deux modèles dans la suite du rapport : un modèle de Poisson simple et un modèle de Poisson quadratique.

8 Découpage apprentissage-validation

Conformément à la méthodologie du TP, la base a été divisée en deux parties :

80% pour l'échantillon d'apprentissage,

20% pour l'échantillon de validation.

Afin de conserver une répartition équilibrée entre les individus n'ayant reçu aucune récompense et ceux ayant reçu au moins une récompense, le découpage a été réalisé en tenant compte de la variable binaire :

$$Awards_binary = \begin{cases} 1 & \text{si } Awards > 0, \\ 0 & \text{si } Awards = 0. \end{cases}$$

Les dimensions obtenues sont :

$$n_{\text{train}} = 159,$$

$$n_{\text{test}} = 41.$$

Le tableau suivant présente la distribution de **Awards** dans les deux échantillons.

TABLE 8.1 – Distribution de **Awards** dans les échantillons d'apprentissage et de validation

Awards	Apprentissage	Validation
0	99	25
1	35	14
2	13	0
3	7	2
4	2	0
5	2	0
6	1	0

La proportion de zéros est très proche dans les deux échantillons :

0.6226415 dans l'échantillon d'apprentissage,

0.6097561 dans l'échantillon de validation.

Cette proximité indique que la division conserve correctement la structure principale de la variable réponse.

Les moyennes et variances de la variable **Awards** dans les deux échantillons sont les suivantes.

TABLE 8.2 – Moyenne et variance de **Awards** selon l'échantillon

Échantillon	Moyenne	Variance
Apprentissage	0.666667	1.2489451
Validation	0.4878049	0.5560976

Dans l'échantillon d'apprentissage, la variance est supérieure à la moyenne. Ce résultat rappelle la possibilité d'une surdispersion. Cependant, le diagnostic final devra être réalisé après ajustement du modèle à l'aide de la déviance résiduelle et de la statistique de Pearson.

9 Conclusion de l'analyse exploratoire

L'analyse exploratoire permet de dégager plusieurs éléments importants.

Premièrement, la variable **Awards** est bien une variable de comptage, car elle prend des valeurs entières positives ou nulles. Deuxièmement, la distribution de cette variable est fortement concentrée en zéro, avec 62% d'observations égales à zéro. Troisièmement, la variance empirique de **Awards** est supérieure à sa moyenne dans l'ensemble de la base, ce qui suggère une possible surdispersion initiale. Toutefois, cette question sera examinée plus rigoureusement après estimation du modèle.

Enfin, la relation entre **Math_Score** et **Awards** est fortement positive. Les coefficients de corrélation de Pearson et de Spearman dépassent tous deux 0.86. Cette relation justifie l'utilisation de **Math_Score** comme variable explicative dans le modèle de régression de Poisson.

La suite du rapport sera consacrée à la méthodologie d'estimation et à l'ajustement des modèles de Poisson simple et quadratique.

Chapitre 4

Méthodologie de modélisation

1 Introduction

Ce chapitre présente la méthodologie adoptée pour construire, estimer, valider et comparer les modèles de régression de Poisson appliqués à la variable **Awards**. L'objectif est de suivre une démarche statistique cohérente avec la nature de la variable réponse et avec les étapes de modélisation vues dans le cours sur les modèles linéaires généralisés.

La démarche retenue peut être résumée comme suit :

Préparation des données $\longrightarrow$ Découpage apprentissage-validation $\longrightarrow$ Estimation des modèles $\longrightarrow$ Tes

2 Préparation des données

Après l'importation de la base sous R, une première étape de préparation a été réalisée. La variable explicative initialement nommée **Math Score** contenait un espace dans son nom. Pour faciliter son utilisation dans les formules R, elle a été renommée :

Math Score $\longrightarrow$ **Math_Score**.

La base utilisée pour l'analyse contient donc les variables suivantes :

- **Awards** : variable réponse ;
- **Math_Score** : variable explicative ;
- **Awards_binary** : variable binaire utilisée pour la validation ROC.

La variable binaire **Awards_binary** est définie par :

$$Awards_binary_i = \begin{cases} 1 & \text{si } Awards_i > 0, \\ 0 & \text{si } Awards_i = 0. \end{cases}$$

Cette transformation n'est pas utilisée pour estimer le modèle de Poisson, car le modèle principal porte bien sur la variable de comptage **Awards**. Elle est utilisée uniquement pour construire la courbe ROC, qui nécessite une variable réponse binaire.

3 Découpage apprentissage-validation

Conformément aux consignes du TP, les données ont été divisées en deux sous-échantillons :

80% pour l'apprentissage,

20% pour la validation.

L'échantillon d'apprentissage est utilisé pour estimer les paramètres des modèles. L'échantillon de validation est conservé à part afin d'évaluer la qualité prédictive des modèles sur des observations non utilisées lors de l'estimation.

Le découpage obtenu est le suivant :

$$n_{\text{train}} = 159,$$

$$n_{\text{test}} = 41.$$

Afin de conserver une structure comparable entre les deux échantillons, le découpage a été réalisé en tenant compte de la variable **Awards_binary**. Cela permet de garder une proportion proche d'individus ayant zéro récompense et d'individus ayant au moins une récompense dans les deux sous-échantillons.

4 Modèle de Poisson simple

Le premier modèle estimé est un modèle de régression de Poisson simple, dans lequel le nombre moyen de récompenses est expliqué uniquement par le score en mathématiques.

On suppose que :

$$Awards_i \mid Math_Score_i \sim \mathcal{P}(\lambda_i).$$

Le modèle est formulé avec un lien logarithmique :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 Math_Score_i.$$

De manière équivalente :

$$\lambda_i = \exp(\beta_0 + \beta_1 Math_Score_i).$$

Dans ce modèle, λ_i représente le nombre moyen attendu de récompenses pour un individu ayant un score donné en mathématiques.

L'estimation sous R est réalisée à l'aide de la fonction `glm()` :

```
glm(Awards ~ Math_Score, family = poisson(link = "log")).
```

5 Modèle de Poisson quadratique

L'analyse exploratoire a montré une relation croissante entre `Math_Score` et `Awards`. Toutefois, cette relation peut ne pas être strictement log-linéaire. Pour tenir compte d'une éventuelle courbure dans la relation, un second modèle est considéré.

Le modèle quadratique est défini par :

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 Math_Score_i + \beta_2 Math_Score_i^2.$$

Ce modèle permet de tester si l'effet du score en mathématiques sur le nombre moyen de récompenses varie selon le niveau du score.

L'estimation sous R est réalisée par :

```
glm(Awards ~ Math_Score + I(Math_Score^2), family = poisson(link = "log")).
```

Le terme $\beta_2 Math_Score_i^2$ introduit une flexibilité supplémentaire. Si β_2 est significatif, cela signifie que l'effet du score en mathématiques n'est pas constant sur toute l'échelle du score.

6 Estimation par maximum de vraisemblance

Les paramètres des modèles de Poisson sont estimés par maximum de vraisemblance. Pour chaque individu i , la probabilité d'observer $Awards_i = y_i$ est donnée par :

$$\mathbb{P}(Y_i = y_i \mid X_i) = \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

La vraisemblance totale est :

$$L(\beta) = \prod_{i=1}^n \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

La log-vraisemblance est donc :

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln(\lambda_i) - \lambda_i - \ln(y_i!)] .$$

Les estimateurs sont obtenus en maximisant cette log-vraisemblance :

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta).$$

Dans R, cette maximisation est effectuée numériquement par la fonction `glm()`, à travers un algorithme itératif de type Fisher scoring.

7 Tests de significativité

Après estimation, deux niveaux de significativité sont étudiés :

1. la significativité individuelle des coefficients ;
2. la significativité globale du modèle.

7.1 Test individuel de Wald

Pour chaque coefficient β_j , on teste :

$$H_0 : \beta_j = 0$$

contre :

$$H_1 : \beta_j \neq 0.$$

La statistique utilisée est :

$$z_j = \frac{\hat{\beta}_j}{\widehat{\sigma}(\hat{\beta}_j)}.$$

Si la p-value associée est inférieure à 5%, le coefficient est considéré comme significativement différent de zéro.

7.2 Test global par rapport de vraisemblance

Le test global permet de comparer le modèle avec variables explicatives au modèle réduit à la constante.

Le modèle réduit est :

$$M_0 : \ln(\lambda_i) = \beta_0.$$

Le modèle complet est :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i.$$

On teste :

$$H_0 : \beta_1 = 0$$

contre :

$$H_1 : \beta_1 \neq 0.$$

La statistique du rapport de vraisemblance est calculée par :

$$LR = D_{\text{réduit}} - D_{\text{complet}}.$$

Sous l'hypothèse nulle, cette statistique suit approximativement une loi du khi-deux.

8 Adéquation des modèles

La significativité d'un modèle ne suffit pas à conclure qu'il est adéquat. Il faut également vérifier que le modèle représente correctement les données observées.

Deux statistiques d'adéquation sont utilisées :

- la déviance résiduelle ;
- la statistique de Pearson.

8.1 Déviance résiduelle

La déviance résiduelle du modèle de Poisson est donnée par :

$$D = 2 \sum_{i=1}^n \left[y_i \ln \left(\frac{y_i}{\hat{\lambda}_i} \right) - (y_i - \hat{\lambda}_i) \right].$$

Lorsque $y_i = 0$, le terme logarithmique est pris égal à zéro.

Le rapport utilisé pour diagnostiquer la dispersion est :

$$\frac{D}{ddl}.$$

Si ce rapport est proche de 1, l'ajustement est considéré comme satisfaisant. Une valeur nettement supérieure à 1 indique une possible surdispersion.

8.2 Statistique de Pearson

La statistique de Pearson est définie par :

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\lambda}_i)^2}{\hat{\lambda}_i}.$$

On étudie également le rapport :

$$\frac{X^2}{ddl}.$$

Ce rapport permet de vérifier si la variance observée est compatible avec l'hypothèse de Poisson.

9 Analyse des résidus

L'analyse des résidus permet de compléter le diagnostic d'adéquation. Deux types de résidus sont utilisés.

9.1 Résidus de Pearson

Les résidus de Pearson sont définis par :

$$r_{P,i} = \frac{y_i - \hat{\lambda}_i}{\sqrt{\hat{\lambda}_i}}.$$

9.2 Résidus de déviance

Les résidus de déviance sont définis par :

$$r_{D,i} = \text{signe}(y_i - \hat{\lambda}_i) \sqrt{2 \left[y_i \ln \left(\frac{y_i}{\hat{\lambda}_i} \right) - (y_i - \hat{\lambda}_i) \right]}.$$

Dans l'analyse empirique, on examine les résidus afin d'identifier d'éventuelles observations atypiques. Une attention particulière est accordée aux observations pour lesquelles :

$$|r_i| > 2.$$

10 Comparaison des modèles

Deux modèles sont comparés dans ce travail :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i,$$

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

La comparaison repose sur plusieurs critères :

- le critère AIC ;
- le test du rapport de vraisemblance entre modèles emboîtés ;
- les indicateurs de prédiction sur l'échantillon test ;
- la courbe ROC.

10.1 Critère AIC

Le critère AIC est défini par :

$$AIC = -2\ell(\hat{\beta}) + 2k.$$

Le meilleur modèle selon l'AIC est celui qui possède la valeur la plus faible.

10.2 Test entre modèles emboîtés

Le modèle M_1 est emboîté dans le modèle M_2 . On peut donc tester si l'ajout du terme quadratique améliore significativement l'ajustement.

On teste :

$$H_0 : \beta_2 = 0$$

contre :

$$H_1 : \beta_2 \neq 0.$$

La statistique utilisée est :

$$LR = D_{M_1} - D_{M_2}.$$

Si la p-value est inférieure à 5%, l'ajout du terme quadratique est statistiquement justifié.

11 Validation prédictive sur l'échantillon test

Après estimation des modèles sur l'échantillon d'apprentissage, les prédictions sont calculées sur l'échantillon de validation.

Pour chaque observation test, la prédiction du nombre moyen de récompenses est :

$$\hat{\lambda}_i = \exp(X_i' \hat{\beta}).$$

La performance prédictive est évaluée à l'aide des indicateurs suivants.

11.1 Erreur absolue moyenne

$$MAE = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} |y_i - \hat{\lambda}_i|.$$

11.2 Racine de l'erreur quadratique moyenne

$$RMSE = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (y_i - \hat{\lambda}_i)^2}.$$

11.3 Déviance de Poisson sur l'échantillon test

La déviance de Poisson est également calculée sur l'échantillon test afin d'évaluer la qualité prédictive du modèle sur des données non utilisées pour l'estimation.

12 Courbe ROC et classification

Même si le modèle de Poisson est un modèle de comptage, la consigne du TP demande une comparaison à l'aide de la courbe ROC. Pour cela, la variable réponse est transformée en variable binaire :

$$Awards_binary_i = \begin{cases} 1 & \text{si } Awards_i > 0, \\ 0 & \text{si } Awards_i = 0. \end{cases}$$

À partir du modèle de Poisson, on calcule la probabilité prédite d'avoir au moins une récompense :

$$\hat{P}(Awards_i > 0) = 1 - \exp(-\hat{\lambda}_i).$$

Cette probabilité est utilisée comme score de classification pour construire la courbe ROC.

L'aire sous la courbe ROC, notée AUC, permet d'évaluer la capacité du modèle à distinguer les individus ayant obtenu au moins une récompense de ceux n'en ayant obtenu aucune.

Le seuil de classification optimal est choisi à l'aide de l'indice de Youden :

$$J = Sensibilité + Spécificité - 1.$$

La matrice de confusion permet ensuite de calculer :

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN},$$

$$Sensibilité = \frac{TP}{TP + FN},$$

$$Spécificité = \frac{TN}{TN + FP},$$

$$Précision = \frac{TP}{TP + FP},$$

$$F1 = \frac{2 \times Précision \times Sensibilité}{Précision + Sensibilité}.$$

13 Diagnostic des observations influentes

Enfin, un diagnostic des observations influentes est réalisé pour le modèle final.

Trois éléments sont examinés :

— les résidus de Pearson ;

- le leverage ;
- la distance de Cook.

Une observation peut être considérée comme potentiellement atypique si elle possède un résidu de Pearson élevé, par exemple :

$$|r_{P,i}| > 2.$$

Le leverage mesure l'influence potentielle d'une observation sur l'ajustement du modèle. La distance de Cook permet d'évaluer l'influence globale d'une observation sur les coefficients estimés.

Dans ce travail, les seuils utilisés sont :

$$h_i > \frac{2k}{n}$$

pour le leverage, et

$$D_i > \frac{4}{n}$$

pour la distance de Cook.

14 Synthèse de la méthodologie

La méthodologie adoptée permet de construire une analyse complète et cohérente du modèle de régression de Poisson. Elle commence par une préparation des données et une division apprentissage-validation, puis se poursuit par l'estimation de deux modèles : un modèle simple et un modèle quadratique.

Les modèles sont ensuite évalués selon leur significativité statistique, leur adéquation aux données, leur performance prédictive sur l'échantillon test et leur capacité de discrimination à travers la courbe ROC. Cette démarche permet de retenir le modèle le plus pertinent pour expliquer le nombre de récompenses obtenues en fonction du score en mathématiques.

Chapitre 5

Résultats empiriques des modèles de Poisson

1 Introduction

Ce chapitre présente les résultats empiriques obtenus après estimation des modèles de régression de Poisson sur l'échantillon d'apprentissage. L'objectif est d'analyser l'effet du score en mathématiques sur le nombre de récompenses obtenues.

Deux modèles sont estimés :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i,$$

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

Le premier modèle suppose une relation log-linéaire entre le score en mathématiques et le nombre moyen attendu de récompenses. Le second modèle introduit un terme quadratique afin de prendre en compte une éventuelle non-linéarité.

2 Estimation du modèle de Poisson simple

Le modèle de Poisson simple est défini par :

$$\text{Awards}_i \mid \text{Math_Score}_i \sim \mathcal{P}(\lambda_i),$$

avec :

$$\ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i.$$

L'estimation par maximum de vraisemblance a donné les résultats suivants.

TABLE 2.1 – Résultats d'estimation du modèle de Poisson simple M_1

Variable	Estimate	Std. Error	z-value	p-value
Intercept	-5.626476	0.567117	-9.921186	3.367297×10^{-23}
Math_Score	0.077621	0.006963	11.147816	7.338564×10^{-29}

Le coefficient associé à **Math_Score** est positif :

$$\hat{\beta}_1 = 0.077621.$$

Sa p-value est très inférieure à 5%, ce qui conduit à rejeter l'hypothèse nulle :

$$H_0 : \beta_1 = 0.$$

Ainsi, le score en mathématiques a un effet statistiquement significatif sur le nombre moyen de récompenses.

3 Interprétation des coefficients du modèle simple

Dans un modèle de Poisson avec lien logarithmique, les coefficients s'interprètent à travers leur exponentielle. Pour le modèle M_1 , on obtient :

$$\exp(\hat{\beta}_1) = 1.080713.$$

Cela signifie qu'une augmentation d'un point du score en mathématiques multiplie le nombre moyen attendu de récompenses par :

$$1.080713.$$

L'effet peut être exprimé en pourcentage :

$$\left(\exp(\hat{\beta}_1) - 1 \right) \times 100 = 8.0713\%.$$

Ainsi, selon le modèle simple, chaque point supplémentaire en mathématiques augmente en moyenne le nombre attendu de récompenses d'environ 8.07%, toutes choses

égales par ailleurs.

Les effets multiplicatifs et leurs intervalles de confiance sont présentés dans le tableau suivant.

TABLE 3.1 – Effets multiplicatifs du modèle M_1

Variable	$\exp(\widehat{\beta})$	IC 95% inférieur	IC 95% supérieur
Intercept	0.003601	0.001850	0.010944
Math_Score	1.080713	1.066045	1.095562

4 Significativité globale du modèle simple

Afin d'évaluer la significativité globale du modèle, on compare le modèle complet M_1 au modèle réduit à la constante.

Le modèle réduit est :

$$M_0 : \ln(\lambda_i) = \beta_0.$$

Le modèle complet est :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i.$$

On teste :

$$H_0 : \beta_1 = 0$$

contre :

$$H_1 : \beta_1 \neq 0.$$

Les résultats du test du rapport de vraisemblance sont les suivants.

TABLE 4.1 – Test global du modèle de Poisson simple M_1

Indicateur	Valeur
Déviance du modèle réduit	244.0146
Déviance du modèle complet	30.3830
Statistique LR	213.6316
Degrés de liberté	1
p-value	2.216116×10^{-48}
Pseudo- R^2	0.875487

La p-value du test global est extrêmement faible. On rejette donc l'hypothèse nulle selon laquelle le score en mathématiques n'a aucun effet sur le nombre de récompenses.

Le pseudo- R^2 est égal à :

$$R_{\text{pseudo}}^2 = 0.875487.$$

Cela indique que le modèle avec `Math_Score` améliore fortement l'ajustement par rapport au modèle réduit à la constante.

5 Adéquation du modèle simple

La significativité du modèle ne suffit pas pour conclure que le modèle est adéquat. Il faut également vérifier si le modèle ajuste correctement les données observées. Pour cela, on utilise la déviance résiduelle et la statistique de Pearson.

Les résultats d'adéquation du modèle M_1 sont présentés dans le tableau suivant.

TABLE 5.1 – Adéquation du modèle de Poisson simple M_1

Indicateur	Valeur
Déviance résiduelle	30.38299
Degrés de liberté	157
p-value du test de déviance	1
Déviance / ddl	0.1935222
Statistique de Pearson	28.57587
p-value du test de Pearson	1
Pearson / ddl	0.1820119

La déviance résiduelle est très inférieure aux degrés de liberté :

$$D = 30.38299 < 157.$$

Le rapport déviance sur degrés de liberté est :

$$\frac{D}{ddl} = 0.1935222.$$

De même, le rapport de Pearson est :

$$\frac{X^2}{ddl} = 0.1820119.$$

Ces deux rapports sont très inférieurs à 1. On ne détecte donc pas de surdispersion. Au contraire, les résultats suggèrent une sous-dispersion ou un ajustement très serré du modèle sur l'échantillon d'apprentissage.

6 Analyse des résidus du modèle simple

L'analyse des résidus permet de compléter le diagnostic d'adéquation. Les résidus de Pearson et les résidus de déviance ont été calculés pour le modèle M_1 .

Les résumés numériques obtenus sont les suivants.

TABLE 6.1 – Résumé des résidus du modèle simple M_1

Indicateur	Résidus de Pearson	Résidus de déviance
Minimum	-0.7307	-0.7895
1er quartile	-0.2834	-0.4008
Médiane	-0.2254	-0.3175
Moyenne	-0.0591	-0.1454
3e quartile	0.0418	0.0415
Maximum	1.9756	1.3565
Nombre de résidus avec $ r > 2$	0	0

Aucun résidu de Pearson ni de déviance ne dépasse la valeur absolue de 2. Cela signifie qu'aucune observation ne semble fortement mal ajustée par le modèle simple.





FIGURE 6.1 – Résidus de Pearson du modèle M_1


 FIGURE 6.2 – Valeurs observées et ajustées du modèle M_1

Les graphiques des résidus ne révèlent pas d'observation fortement atypique. Le modèle simple semble donc fournir un ajustement satisfaisant sur l'échantillon d'apprentissage.

7 Estimation du modèle de Poisson quadratique

Le second modèle introduit un terme quadratique du score en mathématiques. Il est défini par :

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

Ce modèle permet d'examiner si l'effet du score en mathématiques varie selon le niveau du score.

Les résultats d'estimation sont présentés dans le tableau suivant.

 TABLE 7.1 – Résultats d'estimation du modèle quadratique M_2

Variable	Estimate	Std. Error	z-value	p-value
Intercept	-14.20	3.362	-4.223	2.41×10^{-5}
Math_Score	0.3332	0.0926	3.598	0.000321
Math_Score ²	-0.001810	0.0006266	-2.889	0.003870

Le coefficient de `Math_Score` est positif et significatif. Le coefficient du terme quadratique est négatif et également significatif au seuil de 5%.

Le modèle estimé peut donc être écrit approximativement sous la forme :

$$\ln(\hat{\lambda}_i) = -14.20 + 0.3332 \text{ Math_Score}_i - 0.001810 \text{ Math_Score}_i^2.$$

8 Interprétation du terme quadratique

Dans le modèle quadratique, l'effet du score en mathématiques n'est pas constant. Il dépend du niveau du score. En effet :

$$\ln(\lambda_i) = \beta_0 + \beta_1 x_i + \beta_2 x_i^2.$$

L'effet marginal du score sur le logarithme du nombre moyen attendu de récompenses est :

$$\frac{\partial \ln(\lambda_i)}{\partial x_i} = \beta_1 + 2\beta_2 x_i.$$

En utilisant les coefficients estimés :

$$\frac{\partial \ln(\lambda_i)}{\partial x_i} = 0.3332 - 2(0.001810)x_i.$$

Donc :

$$\frac{\partial \ln(\lambda_i)}{\partial x_i} = 0.3332 - 0.003620x_i.$$

Le signe positif de $\hat{\beta}_1$ indique que le score en mathématiques augmente le nombre moyen attendu de récompenses. Toutefois, le signe négatif de $\hat{\beta}_2$ indique que cet effet positif diminue progressivement lorsque le score devient élevé.

Autrement dit, le score en mathématiques reste favorable à l'obtention de récompenses, mais l'augmentation marginale du nombre moyen de récompenses devient moins forte aux niveaux élevés du score.

9 Significativité du terme quadratique

Le terme quadratique a une p-value égale à :

$$p = 0.003870.$$

Cette valeur est inférieure au seuil de 5%, ce qui conduit à rejeter l'hypothèse :

$$H_0 : \beta_2 = 0.$$

L'ajout du terme quadratique est donc statistiquement justifié. Cela signifie que la relation entre `Math_Score` et `Awards` n'est pas parfaitement décrite par une relation log-linéaire simple.

10 Adéquation du modèle quadratique

Comme pour le modèle simple, l'adéquation du modèle quadratique est évaluée à l'aide de la déviance résiduelle et de la statistique de Pearson.

Les résultats sont présentés dans le tableau suivant.

TABLE 10.1 – Adéquation du modèle quadratique M_2

Indicateur	Valeur
Déviance résiduelle	18.22468
Degrés de liberté	156
p-value du test de déviance	1
Déviance / ddl	0.1168249
Statistique de Pearson	21.22093
p-value du test de Pearson	1
Pearson / ddl	0.1360316

La déviance résiduelle du modèle quadratique est :

$$D = 18.22468.$$

Les degrés de liberté sont :

$$ddl = 156.$$

Le rapport de dispersion basé sur la déviance est :

$$\frac{D}{ddl} = 0.1168249.$$

Le rapport de dispersion basé sur Pearson est :

$$\frac{X^2}{ddl} = 0.1360316.$$

Ces deux rapports sont très inférieurs à 1. Le modèle quadratique ne présente donc pas de surdispersion. Comme pour le modèle simple, on observe plutôt une sous-dispersion

ou un ajustement très serré.

11 Analyse des résidus du modèle quadratique

Les résidus du modèle quadratique ont également été analysés.

TABLE 11.1 – Résumé des résidus du modèle quadratique M_2

Indicateur	Résidus de Pearson	Résidus de déviance
Minimum	-0.5822	-0.6204
1er quartile	-0.1769	-0.2470
Médiane	-0.0927	-0.1312
Moyenne	-0.0391	-0.0861
3e quartile	-0.0541	-0.0765
Maximum	2.5476	1.5449
Nombre de résidus avec $ r > 2$	1	0

Le modèle quadratique présente une seule observation avec un résidu de Pearson supérieur à 2 en valeur absolue. En revanche, aucun résidu de déviance ne dépasse ce seuil. Cette observation sera examinée dans le diagnostic d'influence.

12 Diagnostic d'influence du modèle quadratique

Le diagnostic d'influence du modèle M_2 repose sur trois indicateurs :

- les résidus de Pearson ;
- le leverage ;
- la distance de Cook.

Les seuils utilisés sont :

$$h_i > \frac{2k}{n} = 0.03773585,$$

$$D_i > \frac{4}{n} = 0.02515723.$$

L'observation présentant un résidu de Pearson supérieur à 2 est donnée dans le tableau suivant.

TABLE 12.1 – Observation atypique selon les résidus de Pearson dans M_2

Index	Awards	Math Score	$\hat{\lambda}$	Résidu Pearson	Cook
138	1	50	0.125942	2.5476	0.0367834

Cette observation correspond à un individu ayant obtenu une récompense malgré un score de 50, alors que le modèle prédit un nombre moyen attendu relativement faible :

$$\hat{\lambda} = 0.125942.$$

Son résidu de Pearson est :

$$r_P = 2.5476.$$

Sa distance de Cook est :

$$Cook = 0.0367834,$$

ce qui dépasse légèrement le seuil de référence :

$$0.02515723.$$

Cependant, son leverage est égal à :

$$h = 0.01767131,$$

ce qui est inférieur au seuil :

$$0.03773585.$$

L'observation est donc modérément influente, mais elle ne présente pas un leverage élevé. Elle n'est pas supprimée de l'analyse. Elle est simplement signalée comme une observation à surveiller.




FIGURE 12.1 – Distance de Cook du modèle M_2




FIGURE 12.2 – Leverage du modèle M_2

13 Synthèse des résultats empiriques

Les résultats empiriques montrent que le score en mathématiques est fortement lié au nombre de récompenses obtenues. Dans le modèle simple, le coefficient de `Math_Score` est positif et très significatif. Une augmentation d'un point du score augmente le nombre moyen attendu de récompenses d'environ 8.07%.

Le modèle quadratique améliore la forme du modèle en introduisant une relation non linéaire. Le terme quadratique est significatif et négatif, ce qui indique que l'effet positif du score en mathématiques diminue progressivement aux niveaux élevés du score.

Les deux modèles ne présentent pas de surdispersion selon la déviance et la statistique de Pearson. Le modèle quadratique présente une observation modérément influente, mais celle-ci ne justifie pas une suppression automatique.

La comparaison finale entre les deux modèles, ainsi que la validation sur l'échantillon test et la courbe ROC, seront présentées dans le chapitre suivant.

Chapitre 6

Validation, comparaison des modèles et choix final

1 Introduction

Après l'estimation des modèles de régression de Poisson sur l'échantillon d'apprentissage, il est nécessaire d'évaluer leur performance sur l'échantillon de validation. Cette étape permet de vérifier si les modèles conservent une bonne qualité prédictive sur des observations qui n'ont pas été utilisées lors de l'estimation.

Dans ce chapitre, on compare les deux modèles considérés :

$$M_1 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i,$$

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

La comparaison repose sur plusieurs critères :

- la qualité prédictive sur l'échantillon test ;
- le critère AIC ;
- le test du rapport de vraisemblance entre modèles emboîtés ;
- la courbe ROC ;
- la matrice de confusion.

2 Validation prédictive du modèle simple M_1

Le modèle simple M_1 a été estimé sur l'échantillon d'apprentissage, puis utilisé pour prédire le nombre moyen attendu de récompenses sur l'échantillon test.

Pour chaque observation test, la prédiction est donnée par :

$$\hat{\lambda}_i = \exp(\hat{\beta}_0 + \hat{\beta}_1 \text{Math_Score}_i).$$

Les résultats obtenus sur l'échantillon test sont les suivants.

TABLE 2.1 – Validation prédictive du modèle simple M_1

Indicateur	Valeur
Moyenne observée sur test	0.4878049
Moyenne prédite sur test	0.4043870
MAE	0.2194727
RMSE	0.2989070
Déviance de Poisson test	9.561734

La moyenne observée sur l'échantillon test est :

$$\overline{Y}_{test} = 0.4878049.$$

La moyenne prédite par le modèle simple est :

$$\overline{\hat{\lambda}}_{test} = 0.4043870.$$

Le modèle simple sous-estime donc légèrement le nombre moyen de récompenses sur l'échantillon test. Toutefois, les erreurs de prédiction restent relativement faibles :

$$MAE = 0.2194727,$$

$$RMSE = 0.2989070.$$




FIGURE 2.1 – Validation du modèle simple M_1 sur l'échantillon test

3 Validation prédictive du modèle quadratique

M_2

Le modèle quadratique M_2 a également été évalué sur l'échantillon test. La prédiction du nombre moyen de récompenses est donnée par :

$$\hat{\lambda}_i = \exp(\hat{\beta}_0 + \hat{\beta}_1 \text{Math_Score}_i + \hat{\beta}_2 \text{Math_Score}_i^2).$$

Les résultats obtenus sont présentés dans le tableau suivant.

TABLE 3.1 – Validation prédictive du modèle quadratique M_2

Indicateur	Valeur
Moyenne observée sur test	0.4878049
Moyenne prédite sur test	0.4481693
MAE	0.127824
RMSE	0.2239236
Déviance de Poisson test	4.604606

La moyenne prédite par le modèle quadratique est :

$$\widehat{\bar{\lambda}}_{test} = 0.4481693.$$

Cette valeur est plus proche de la moyenne observée :

$$\bar{Y}_{test} = 0.4878049.$$

Les erreurs de prédiction sont également plus faibles que celles du modèle simple :

$$MAE = 0.127824,$$

$$RMSE = 0.2239236.$$

La déviance de Poisson sur l'échantillon test est aussi plus faible :

$$D_{test} = 4.604606.$$

Ces résultats indiquent que le modèle quadratique prédit mieux le nombre moyen de récompenses sur l'échantillon de validation.

4 Comparaison prédictive des deux modèles

Le tableau suivant compare directement les performances prédictives des deux modèles.

TABLE 4.1 – Comparaison prédictive des modèles M_1 et M_2

Indicateur	M_1 : Poisson simple	M_2 : Poisson quadratique
Moyenne observée test	0.4878049	0.4878049
Moyenne prédite test	0.4043870	0.4481693
MAE	0.2194727	0.127824
RMSE	0.2989070	0.2239236
Déviance test	9.561734	4.604606
AIC	176.4542	166.2959

Le modèle quadratique M_2 est meilleur que le modèle simple M_1 selon tous les critères prédictifs considérés :

$$MAE(M_2) < MAE(M_1),$$

$$RMSE(M_2) < RMSE(M_1),$$

$$D_{test}(M_2) < D_{test}(M_1).$$

Le critère AIC est également plus faible pour le modèle quadratique :

$$AIC(M_2) = 166.2959 < AIC(M_1) = 176.4542.$$

Ainsi, le modèle quadratique présente un meilleur compromis entre qualité d'ajustement et complexité.

5 Comparaison par test du rapport de vraisemblance

Comme le modèle M_1 est emboîté dans le modèle M_2 , on peut tester l'apport du terme quadratique à l'aide du test du rapport de vraisemblance.

On teste :

$$H_0 : \beta_2 = 0$$

contre :

$$H_1 : \beta_2 \neq 0.$$

Les résultats obtenus sont :

$$D_{M_1} = 30.383,$$

$$D_{M_2} = 18.225.$$

La différence de déviance est :

$$\Delta D = 12.158.$$

La p-value associée est :

$$p = 0.0004887.$$

Cette p-value est inférieure à 5%. On rejette donc l'hypothèse nulle H_0 . L'ajout du terme quadratique améliore significativement l'ajustement du modèle.

6 Construction de la courbe ROC

La courbe ROC nécessite une variable réponse binaire. La variable de comptage `Awards` est donc transformée en variable binaire :

$$Awards_binary_i = \begin{cases} 1 & \text{si } Awards_i > 0, \\ 0 & \text{si } Awards_i = 0. \end{cases}$$

Cette transformation permet d'évaluer la capacité des modèles à distinguer les individus ayant obtenu au moins une récompense de ceux n'en ayant obtenu aucune.

À partir du modèle de Poisson, on sait que :

$$P(Y_i = 0) = e^{-\lambda_i}.$$

Donc :

$$P(Y_i > 0) = 1 - e^{-\lambda_i}.$$

Après estimation, le score prédictif utilisé pour la courbe ROC est donc :

$$\hat{p}_i = 1 - e^{-\hat{\lambda}_i}.$$

7 Résultats de la courbe ROC

Les deux modèles ont été évalués à l'aide de la courbe ROC sur l'échantillon test. Les AUC obtenues sont les suivantes :

TABLE 7.1 – Comparaison des AUC des modèles

Modèle	AUC
M_1 : Poisson simple	0.99375
M_2 : Poisson quadratique	0.99375

Les deux modèles obtiennent la même aire sous la courbe ROC :

$$AUC = 0.99375.$$

Cette valeur est très proche de 1, ce qui indique une excellente capacité de discrimination. Les modèles distinguent très bien les individus ayant obtenu au moins une récompense de ceux qui n'en ont obtenu aucune.




FIGURE 7.1 – Courbe ROC du modèle de Poisson sur l'échantillon test




FIGURE 7.2 – Comparaison des courbes ROC des modèles M_1 et M_2

Les courbes ROC des deux modèles sont pratiquement confondues. Cela signifie que l'ajout du terme quadratique n'améliore pas la capacité de discrimination binaire, même s'il améliore la prédiction du nombre moyen de récompenses.

8 Seuil optimal et matrice de confusion

Le seuil optimal de classification a été choisi à l'aide de l'indice de Youden. Le seuil obtenu est :

$$s^* = 0.2126067.$$

La règle de classification est donc :

$$\hat{Y}_i^* = \begin{cases} 1 & \text{si } \hat{p}_i \geq 0.2126067, \\ 0 & \text{sinon.} \end{cases}$$

La matrice de confusion obtenue sur l'échantillon test est la suivante.

TABLE 8.1 – Matrice de confusion avec le seuil optimal de Youden

	Prédit 0	Prédit 1
Observé 0	24	1
Observé 1	0	16

On obtient donc :

$$TN = 24,$$

$$FP = 1,$$

$$FN = 0,$$

$$TP = 16.$$

Le modèle ne commet aucun faux négatif. Tous les individus ayant obtenu au moins une récompense sont correctement identifiés.

9 Indicateurs de classification

À partir de la matrice de confusion, les indicateurs de classification sont les suivants.

TABLE 9.1 – Indicateurs de classification

Indicateur	Valeur
Seuil optimal de Youden	0.2126067
Accuracy	0.9756098
Sensibilité	1
Spécificité	0.96
Précision	0.9411765
F1-score	0.969697
AUC	0.99375

L'accuracy est :

$$Accuracy = 0.9756098.$$

Cela signifie que 97.56% des observations de l'échantillon test sont correctement classées.

La sensibilité est :

$$Sensibilité = 1.$$

Cela signifie que tous les individus ayant au moins une récompense sont correctement détectés.

La spécificité est :

$$Spécificité = 0.96.$$

Cela signifie que 96% des individus n'ayant aucune récompense sont correctement classés.

La précision est :

$$Précision = 0.9411765.$$

Cela signifie que parmi les individus prédits comme ayant au moins une récompense, environ 94.12% en ont effectivement obtenu au moins une.

Enfin, le F1-score est :

$$F1 = 0.969697.$$

Ce résultat confirme un très bon équilibre entre précision et sensibilité.

10 Choix du modèle final

Le choix du modèle final doit tenir compte de l'ensemble des résultats obtenus. Le modèle simple M_1 est déjà fortement significatif et présente une bonne capacité prédictive. Cependant, le modèle quadratique M_2 améliore plusieurs critères importants.

Le modèle M_2 est meilleur selon l'AIC :

$$AIC(M_2) = 166.2959 < AIC(M_1) = 176.4542.$$

Il améliore également les erreurs de prédiction :

$$MAE(M_2) = 0.127824 < MAE(M_1) = 0.2194727,$$

$$RMSE(M_2) = 0.2239236 < RMSE(M_1) = 0.2989070.$$

La déviance sur l'échantillon test est plus faible :

$$D_{test}(M_2) = 4.604606 < D_{test}(M_1) = 9.561734.$$

Le test du rapport de vraisemblance montre aussi que l'ajout du terme quadratique est significatif :

$$p = 0.0004887.$$

Les deux modèles ont la même AUC :

$$AUC(M_1) = AUC(M_2) = 0.99375.$$

Cela signifie que le modèle quadratique n'améliore pas la discrimination binaire, mais il améliore nettement la prédiction du nombre moyen de récompenses. Ainsi, le modèle final retenu est :

$$M_2 : \ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2$$

Le modèle estimé est :

$$\ln(\widehat{\lambda}_i) = -14.20 + 0.3332 \text{Math_Score}_i - 0.001810 \text{Math_Score}_i^2$$

11 Interprétation du modèle final

Le modèle final indique que le score en mathématiques a un effet positif sur le nombre moyen attendu de récompenses, mais que cet effet n'est pas constant.

Le coefficient positif de `Math_Score` montre que, globalement, une hausse du score augmente le nombre moyen attendu de récompenses. Cependant, le coefficient négatif du terme quadratique montre que cette hausse devient progressivement moins forte lorsque

le score est élevé.

L'effet marginal sur le logarithme du nombre moyen de récompenses est :

$$\frac{\partial \ln(\lambda_i)}{\partial \text{Math_Score}_i} = 0.3332 - 0.003620 \text{ Math_Score}_i.$$

Par exemple, pour un score de 50 :

$$0.3332 - 0.003620(50) = 0.1522.$$

L'effet multiplicatif local est donc :

$$\exp(0.1522) = 1.1644.$$

Cela signifie qu'autour d'un score de 50, un point supplémentaire en mathématiques augmente localement le nombre moyen attendu de récompenses d'environ 16.44%.

Pour un score de 80 :

$$0.3332 - 0.003620(80) = 0.0436.$$

L'effet multiplicatif local est :

$$\exp(0.0436) = 1.0446.$$

Autour d'un score de 80, un point supplémentaire augmente donc le nombre moyen attendu de récompenses d'environ 4.46%.

Cette interprétation confirme que l'effet du score reste positif, mais diminue aux niveaux élevés. Cela justifie le choix du modèle quadratique.

12 Synthèse

La validation et la comparaison des modèles montrent que le modèle quadratique est le plus pertinent pour expliquer le nombre de récompenses. Il améliore l'ajustement, réduit les erreurs de prédiction sur l'échantillon test et conserve une excellente capacité de discrimination.

Le modèle final retenu est donc le modèle de Poisson quadratique. Il permet de prendre en compte une relation non linéaire entre le score en mathématiques et le nombre moyen attendu de récompenses, tout en respectant la nature de comptage de la variable

réponse.

Chapitre 7

Discussion, limites et conclusion générale

1 Introduction

Ce chapitre propose une discussion globale des résultats obtenus dans les chapitres précédents. L'objectif est de revenir sur la problématique initiale, d'interpréter les résultats du modèle final, de discuter la qualité de l'ajustement, puis de présenter les principales limites de l'étude.

La problématique posée au début du rapport était la suivante :

Comment le score en mathématiques permet-il d'expliquer le nombre de récompenses obtenues par un individu dans une compétition académique, à l'aide d'un modèle de régression de Poisson ?

Les résultats empiriques montrent que le score en mathématiques constitue une variable explicative importante du nombre de récompenses. Le modèle final retenu est le modèle de Poisson quadratique :

$$\ln(\hat{\lambda}_i) = -14.20 + 0.3332 \text{ Math_Score}_i - 0.001810 \text{ Math_Score}_i^2.$$

2 Discussion du choix du modèle final

Le modèle de Poisson simple a d'abord permis de mettre en évidence une relation positive et significative entre le score en mathématiques et le nombre moyen de récompenses. Le coefficient associé à **Math_Score** était positif et très significatif :

$$\hat{\beta}_1 = 0.077621,$$

avec une p-value très inférieure à 5%.

L'interprétation multiplicative indiquait qu'une augmentation d'un point du score en mathématiques augmentait le nombre moyen attendu de récompenses d'environ :

$$8.07\%.$$

Cependant, l'estimation du modèle quadratique a montré que la relation entre le score en mathématiques et le nombre de récompenses n'était pas strictement log-linéaire. Le terme quadratique s'est révélé significatif :

$$p = 0.003870.$$

De plus, la comparaison entre les deux modèles a montré que le modèle quadratique améliore l'ajustement et la prédiction. En effet :

$$AIC(M_2) = 166.2959 < AIC(M_1) = 176.4542.$$

Le modèle quadratique présente également de meilleures performances sur l'échantillon de validation :

$$MAE(M_2) = 0.127824 < MAE(M_1) = 0.2194727,$$

$$RMSE(M_2) = 0.2239236 < RMSE(M_1) = 0.2989070,$$

$$D_{test}(M_2) = 4.604606 < D_{test}(M_1) = 9.561734.$$

Ces résultats justifient le choix du modèle quadratique comme modèle final.

3 Interprétation statistique du modèle final

Le modèle final est donné par :

$$\ln(\lambda_i) = \beta_0 + \beta_1 \text{Math_Score}_i + \beta_2 \text{Math_Score}_i^2.$$

Avec les coefficients estimés, on obtient :

$$\ln(\hat{\lambda}_i) = -14.20 + 0.3332 \text{ Math_Score}_i - 0.001810 \text{ Math_Score}_i^2.$$

Le coefficient positif de **Math_Score** montre que le score en mathématiques exerce un effet favorable sur le nombre moyen attendu de récompenses. Cependant, le coefficient négatif du terme quadratique montre que cet effet favorable diminue progressivement lorsque le score devient élevé.

L'effet marginal du score sur le logarithme du nombre moyen attendu de récompenses est :

$$\frac{\partial \ln(\lambda_i)}{\partial \text{Math_Score}_i} = 0.3332 - 0.003620 \text{ Math_Score}_i.$$

Cela signifie que l'effet d'un point supplémentaire de score dépend du niveau initial du score.

Par exemple, pour un score de 50, l'effet marginal est :

$$0.3332 - 0.003620(50) = 0.1522.$$

L'effet multiplicatif correspondant est :

$$\exp(0.1522) = 1.1644.$$

Ainsi, autour d'un score de 50, un point supplémentaire en mathématiques augmente le nombre moyen attendu de récompenses d'environ :

$$16.44\%.$$

Pour un score de 80, l'effet marginal devient :

$$0.3332 - 0.003620(80) = 0.0436.$$

L'effet multiplicatif est :

$$\exp(0.0436) = 1.0446.$$

Ainsi, autour d'un score de 80, un point supplémentaire augmente le nombre moyen attendu de récompenses d'environ :

4.46%.

L'effet reste donc positif, mais il devient progressivement plus faible lorsque le score augmente.

4 Interprétation pratique

D'un point de vue pratique, les résultats indiquent que les individus ayant de meilleurs scores en mathématiques ont tendance à obtenir davantage de récompenses. Cette conclusion est cohérente avec l'idée selon laquelle une meilleure performance académique augmente les chances de distinction dans une compétition.

Cependant, le modèle quadratique montre que cette relation n'est pas simplement linéaire. L'effet du score est plus marqué aux niveaux faibles et intermédiaires, puis devient moins intense aux niveaux élevés. Cela peut s'interpréter par un effet de seuil : lorsque les scores sont déjà élevés, un point supplémentaire améliore encore le nombre moyen attendu de récompenses, mais de manière moins importante.

Autrement dit, passer d'un score moyen à un bon score semble avoir un effet plus fort que passer d'un très bon score à un score encore plus élevé.

5 Qualité d'ajustement du modèle final

L'adéquation du modèle final a été évaluée à l'aide de la déviance résiduelle et de la statistique de Pearson.

Pour le modèle quadratique, les résultats obtenus sont :

$$D = 18.22468,$$

$$ddl = 156,$$

$$\frac{D}{ddl} = 0.1168249.$$

La statistique de Pearson donne :

$$X^2 = 21.22093,$$

$$\frac{X^2}{ddl} = 0.1360316.$$

Ces deux rapports sont très inférieurs à 1. Le modèle ne présente donc pas de surdispersion. Au contraire, les résultats indiquent une sous-dispersion ou un ajustement très serré.

La surdispersion aurait été problématique, car elle aurait remis en question l'hypothèse fondamentale du modèle de Poisson :

$$\mathbb{E}(Y_i | X_i) = \text{Var}(Y_i | X_i) = \lambda_i.$$

Dans notre cas, les statistiques d'adéquation ne révèlent pas de surdispersion. Le modèle de Poisson reste donc acceptable pour cette base.

6 Performance prédictive

La validation sur l'échantillon test confirme la bonne performance du modèle final. La moyenne observée du nombre de récompenses sur l'échantillon test est :

$$\overline{Y}_{test} = 0.4878049.$$

La moyenne prédite par le modèle quadratique est :

$$\widehat{\lambda}_{test} = 0.4481693.$$

L'écart entre les deux moyennes est faible, ce qui montre que le modèle reproduit correctement le niveau moyen du phénomène étudié.

Les erreurs de prédiction sont également limitées :

$$MAE = 0.127824,$$

$$RMSE = 0.2239236.$$

Ces valeurs indiquent que le modèle quadratique fournit des prédictions précises du nombre moyen attendu de récompenses.

7 Performance de classification

Pour répondre à l'exigence du TP concernant la courbe ROC, la variable **Awards** a été transformée en variable binaire :

$$Awards_binary_i = \begin{cases} 1 & \text{si } Awards_i > 0, \\ 0 & \text{si } Awards_i = 0. \end{cases}$$

À partir du modèle de Poisson, la probabilité prédite d'avoir au moins une récompense est :

$$\hat{P}(Awards_i > 0) = 1 - \exp(-\hat{\lambda}_i).$$

La courbe ROC a donné une aire sous la courbe égale à :

$$AUC = 0.99375.$$

Cette valeur est très proche de 1, ce qui indique une excellente capacité de discrimination entre les individus ayant obtenu au moins une récompense et ceux n'en ayant obtenu aucune.

Avec le seuil optimal de Youden :

$$s^* = 0.2126067,$$

la matrice de confusion obtenue est :

$$TN = 24, \quad FP = 1, \quad FN = 0, \quad TP = 16.$$

Les indicateurs associés sont :

$$Accuracy = 0.9756098,$$

$$Sensibilité = 1,$$

$$Spécificité = 0.96,$$

$$Précision = 0.9411765,$$

$$F1 = 0.969697.$$

Ces résultats montrent que le modèle identifie correctement tous les individus ayant obtenu au moins une récompense et commet seulement un faux positif.

8 Discussion des observations influentes

Le diagnostic d'influence du modèle final a mis en évidence une observation particulière. Cette observation correspond à :

$$Awards = 1,$$

$$Math_Score = 50.$$

Le modèle prédit pour cette observation :

$$\hat{\lambda} = 0.125942.$$

Son résidu de Pearson est :

$$r_P = 2.5476.$$

Sa distance de Cook est :

$$Cook = 0.0367834,$$

ce qui dépasse légèrement le seuil de référence :

$$0.02515723.$$

Cependant, son leverage est :

$$h = 0.01767131,$$

ce qui reste inférieur au seuil :

0.03773585.

Cette observation est donc modérément influente, mais elle ne présente pas un leverage élevé. Elle n’a pas été supprimée, car aucune justification statistique forte ne permet de la considérer comme une erreur ou comme une observation aberrante à exclure.

Cette décision est importante : une observation influente ne doit pas être supprimée automatiquement. Elle doit être analysée, interprétée et conservée si elle correspond à une situation possible dans les données.

9 Limites de l’étude

Malgré la qualité des résultats obtenus, plusieurs limites doivent être mentionnées.

9.1 Nombre limité de variables explicatives

La base utilisée contient uniquement une variable explicative : `Math_Score`. Le modèle explique donc le nombre de récompenses seulement à partir du score en mathématiques.

Or, dans une compétition académique, d’autres facteurs peuvent influencer le nombre de récompenses, par exemple :

- le score dans d’autres matières ;
- le niveau général de l’étudiant ;
- la participation à plusieurs épreuves ;
- l’expérience ou la préparation ;
- le type de compétition.

L’absence de ces variables limite l’interprétation causale du modèle.

9.2 Forte proportion de zéros

La variable `Awards` contient une proportion importante de zéros :

62%.

Cela signifie qu’une majorité d’individus n’a obtenu aucune récompense. Le modèle de Poisson parvient à bien s’ajuster dans cette étude, mais dans d’autres contextes, une telle concentration en zéro pourrait justifier l’utilisation de modèles spécifiques, comme :

- le modèle de Poisson à inflation de zéros ;
- le modèle binomial négatif à inflation de zéros.

9.3 Sous-dispersion

Les rapports de dispersion obtenus sont très inférieurs à 1 :

$$\frac{D}{ddl} = 0.1168249,$$

$$\frac{X^2}{ddl} = 0.1360316.$$

Cela indique une sous-dispersion ou un ajustement très serré. Même si cela ne remet pas en cause directement le modèle de Poisson dans ce travail, ce résultat doit être mentionné comme une particularité de la base.

9.4 Taille de l'échantillon de validation

L'échantillon de validation contient seulement :

$$n_{\text{test}} = 41$$

observations.

Cette taille reste suffisante pour une première validation, mais elle demeure relativement limitée. Les performances prédictives, notamment l'AUC et la matrice de confusion, pourraient être plus stables avec un échantillon test plus grand.

10 Prolongements possibles

Plusieurs prolongements peuvent être envisagés afin d'améliorer ou d'approfondir l'analyse.

10.1 Ajouter d'autres variables explicatives

Un premier prolongement consisterait à enrichir la base avec d'autres variables explicatives. Cela permettrait de construire un modèle plus complet et de mieux comprendre les facteurs associés au nombre de récompenses.

10.2 Tester d'autres modèles de comptage

Même si le modèle de Poisson s'est montré satisfaisant dans cette étude, il serait possible de comparer ses résultats à d'autres modèles de comptage, notamment :

- le modèle quasi-Poisson ;
- le modèle binomial négatif ;
- le modèle de Poisson à inflation de zéros.

Ces modèles seraient particulièrement utiles si une surdispersion ou une inflation de zéros plus forte était observée.

10.3 Utiliser une validation croisée

Enfin, au lieu d'une seule division apprentissage-validation, on pourrait utiliser une validation croisée. Cela permettrait d'évaluer la stabilité des performances du modèle sur plusieurs découpages de la base.

11 Conclusion générale

Ce travail avait pour objectif d'appliquer un modèle de régression de Poisson à une variable de comptage représentant le nombre de récompenses obtenues par des individus dans une compétition académique.

L'analyse descriptive a d'abord montré que la variable **Awards** est bien une variable de comptage, prenant des valeurs entières positives ou nulles. Elle présente une forte concentration en zéro, avec 62% d'observations égales à zéro. La variable explicative **Math_Score** présente une relation positive forte avec **Awards**, avec des corrélations de Pearson et de Spearman supérieures à 0.86.

Un premier modèle de Poisson simple a été estimé. Il a montré que le score en mathématiques a un effet positif et très significatif sur le nombre moyen de récompenses. Chaque point supplémentaire en mathématiques augmente le nombre moyen attendu de récompenses d'environ 8.07% dans le modèle simple.

Un second modèle, intégrant un terme quadratique, a ensuite été estimé. Ce modèle a montré que l'effet du score en mathématiques est non linéaire : il reste positif, mais diminue progressivement lorsque le score devient élevé.

La comparaison des modèles a conduit à retenir le modèle quadratique comme modèle final. Ce choix est justifié par un AIC plus faible, une meilleure prédiction sur l'échantillon test, une déviance test plus faible et un test du rapport de vraisemblance significatif.

Le modèle final retenu est :

$$\ln(\hat{\lambda}_i) = -14.20 + 0.3332 \text{ Math_Score}_i - 0.001810 \text{ Math_Score}_i^2$$

La validation par courbe ROC a montré une excellente capacité de discrimination, avec :

$$AUC = 0.99375.$$

La matrice de confusion a donné une accuracy de 97.56%, une sensibilité de 1 et une spécificité de 0.96.

Ainsi, le modèle de Poisson quadratique permet d'expliquer efficacement le nombre de récompenses obtenues à partir du score en mathématiques. Il respecte la nature de comptage de la variable réponse, fournit une interprétation statistique claire et présente de bonnes performances prédictives.

En conclusion, le score en mathématiques apparaît comme un facteur fortement associé au nombre de récompenses obtenues, mais son effet marginal diminue lorsque le score atteint des niveaux élevés. Cette conclusion illustre l'intérêt des modèles linéaires généralisés pour traiter des variables de comptage et montre l'importance de comparer plusieurs spécifications avant de retenir un modèle final.

Chapitre 8

Annexe : Code R et ressources numériques

1 Disponibilité du code

Afin d’assurer la reproductibilité des résultats présentés dans ce rapport, l’ensemble du code utilisé pour l’analyse statistique est disponible dans un dépôt GitHub public.

Ce dépôt contient la base de données, le script d’analyse sous R/R Markdown, les sorties graphiques et le rapport final. Cette organisation permet au lecteur d’accéder directement aux ressources numériques du projet sans alourdir le rapport avec un grand nombre de lignes de code.

2 Lien vers le dépôt GitHub

Le dépôt GitHub du projet est accessible à l’adresse suivante :

[Accéder au dépôt GitHub du projet](#)

3 Packages utilisés

Les principaux packages R utilisés dans l’analyse sont :

- `readxl` pour l’importation du fichier Excel ;
- `dplyr` pour la manipulation des données ;
- `ggplot2` pour les représentations graphiques ;
- `pROC` pour la construction et l’analyse de la courbe ROC.

4 Conclusion

Cette annexe permet de garantir la transparence et la reproductibilité du travail

réalisé. Le lecteur peut consulter le dépôt GitHub pour accéder directement au code source, aux données et aux fichiers associés au projet.